

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Media sosial telah menjadi salah satu platform utama untuk berdiskusi mengenai berbagai isu, termasuk kesehatan mental. Platform X, yang sering digunakan untuk berbagi informasi dan pengalaman pribadi, memiliki berbagai konten bertema kesehatan mental seperti depresi, skizofrenia, dan bipolar. Diskusi ini memiliki peran penting dalam meningkatkan kesadaran publik dan memberikan dukungan emosional kepada individu yang terlibat. Namun, variasi makna dan konteks dari topik yang dibahas sering kali sulit dipahami secara manual, terutama mengingat volume data yang sangat besar yang dihasilkan setiap harinya di media sosial.

Berbagai penelitian menunjukkan bahwa informasi yang berasal dari media sosial dapat dimanfaatkan untuk analisis lebih lanjut terkait kesehatan mental. Sebagai contoh, studi oleh Chancellor et al. (2016) menyatakan bahwa platform media sosial memberikan wawasan unik tentang pola komunikasi dan ekspresi emosi pengguna yang dapat digunakan untuk intervensi kesehatan. Namun, analisis manual atas data ini memakan waktu dan rawan bias. Oleh karena itu, pendekatan berbasis teknologi, seperti Natural Language Processing (NLP), menjadi solusi potensial.

Teknologi NLP telah menunjukkan kemajuan signifikan dengan hadirnya model seperti BERT (Bidirectional Encoder Representations from Transformers). BERT memungkinkan analisis teks secara mendalam dengan memahami konteks semantik dari kata-kata dalam sebuah kalimat. Hal ini menjadikannya alat yang sangat baik untuk mengklasifikasikan tema diskusi yang kompleks seperti kesehatan mental. Dalam konteks ini, BERT dapat digunakan untuk menghasilkan representasi fitur teks yang kaya, yang kemudian diproses oleh model Logistic Regression untuk menghasilkan klasifikasi yang efisien. Kombinasi ini tidak hanya menjanjikan hasil yang akurat tetapi juga lebih sederhana dibandingkan dengan penggunaan model yang lebih kompleks seperti Neural Networks.

Implementasi sistem klasifikasi otomatis ini relevan karena dapat membantu mempermudah analisis data dalam jumlah besar, khususnya dalam memahami pola diskusi kesehatan mental di media sosial. Menurut penelitian yang dilakukan oleh Smith et al. (2019), analisis berbasis NLP pada data media sosial memberikan wawasan yang berharga dalam memahami perilaku pengguna, yang berimplikasi langsung pada pengembangan strategi intervensi kesehatan. Penelitian ini juga mendukung penggunaan teknologi berbasis NLP untuk tugas-tugas yang memerlukan klasifikasi data yang kompleks.

Dengan demikian, penelitian ini bertujuan untuk mengembangkan sistem klasifikasi otomatis yang dapat membantu mengidentifikasi tema diskusi kesehatan mental di media sosial X secara sistematis. Pendekatan ini diharapkan dapat meningkatkan efisiensi analisis dan memberikan kontribusi dalam bidang kesehatan mental berbasis teknologi.

1.2 Rumusan Masalah

Rumusan masalah yang menjadi fokus penelitian ini adalah:

1. Bagaimana membangun model klasifikasi yang akurat untuk mengidentifikasi tema diskusi kesehatan mental di media sosial X?
2. Bagaimana penggunaan BERT sebagai representasi fitur dapat meningkatkan akurasi klasifikasi dibandingkan metode tradisional?
3. Bagaimana performa Logistic Regression dibandingkan dengan model lain dalam klasifikasi diskusi kesehatan mental?

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Mengembangkan model klasifikasi diskusi kesehatan mental dengan memanfaatkan representasi fitur teks dari BERT.
2. Menganalisis efisiensi Logistic Regression sebagai model klasifikasi utama dalam tugas ini.
3. Membandingkan performa Logistic Regression dengan metode lain seperti Support Vector Machine (SVM) dan Neural Networks.

1.4 Batasan Masalah

Penelitian ini memiliki beberapa batasan, yaitu:

1. Data diskusi hanya diambil dari platform media sosial X dengan fokus tema kesehatan mental.
2. Penelitian terbatas pada penggunaan BERT untuk representasi fitur teks.
3. Logistic Regression dijadikan model klasifikasi utama, sementara model lain digunakan sebagai pembanding.
4. Tidak mencakup analisis mendalam terhadap aspek psikologis yang memengaruhi diskusi.

1.5 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat yang lebih terperinci sebagai berikut:

1. Manfaat Akademik:

- Memberikan kontribusi signifikan dalam pengembangan teknologi klasifikasi otomatis berbasis NLP khususnya di domain kesehatan mental.
- Mengisi kesenjangan penelitian terkait efektivitas model Logistic Regression dibandingkan metode yang lebih kompleks.
- Membuka peluang eksplorasi lebih lanjut mengenai penerapan BERT pada domain analisis teks lainnya.

2. Manfaat Praktis:

- Memberikan alat bantu yang dapat digunakan oleh praktisi kesehatan mental untuk menganalisis pola diskusi di media sosial secara efisien.
- Mempermudah identifikasi tema-tema utama dalam diskusi kesehatan mental untuk mendukung intervensi berbasis data.
- Meningkatkan kesadaran masyarakat melalui analisis mendalam terhadap tema-tema yang sering muncul di media sosial.

3. Manfaat Teknis:

- Membuktikan bahwa model Logistic Regression dapat digunakan secara efektif dalam tugas klasifikasi berbasis BERT.

- Memberikan solusi komputasi yang lebih ringan dibandingkan metode kompleks lainnya tanpa mengorbankan akurasi.

BAB 2

KAJIAN PUSTAKA

2.1 Data Mining

Data mining adalah proses penggalian informasi atau pola dari dataset yang besar dengan tujuan untuk mendapatkan wawasan yang bermanfaat. Proses ini melibatkan teknik statistik, pembelajaran mesin, dan analisis data untuk mengidentifikasi pola tersembunyi. Dalam konteks penelitian ini, data mining digunakan untuk mengumpulkan dan menganalisis data diskusi kesehatan mental di media sosial. Teknik seperti crawling data, preprocessing, dan analisis fitur menjadi bagian penting dari proses ini.

Menurut Han et al. (2012), data mining mencakup berbagai tahap, termasuk pengumpulan data, preprocessing, ekstraksi fitur, analisis data, dan visualisasi hasil. Dalam penelitian ini, data mining diterapkan untuk mendukung klasifikasi diskusi kesehatan mental dengan memanfaatkan data dari platform media sosial.

Dalam konteks penelitian ini, data mining diterapkan untuk mengumpulkan dan menganalisis data dari diskusi-diskusi yang berkaitan dengan kesehatan mental yang ditemukan di media sosial. Platform seperti Twitter, Facebook, atau forum daring lainnya menjadi sumber utama data yang bisa dianalisis. Proses data mining dalam penelitian ini terdiri dari beberapa tahapan penting, yaitu:

1. **Pengumpulan Data:** Langkah pertama dalam data mining adalah mengumpulkan data dari sumber yang relevan. Untuk penelitian ini, data dikumpulkan menggunakan teknik crawling atau pengambilan data secara otomatis dari platform media sosial. Data ini biasanya berupa teks dalam bentuk tweet, status, komentar, atau postingan lainnya yang mengandung topik tertentu.
2. **Preprocessing Data:** Setelah data terkumpul, tahap berikutnya adalah pembersihan dan persiapan data (preprocessing). Proses ini penting untuk menghilangkan noise dalam data, seperti URL, mention (@), hashtag (#), atau karakter-karakter khusus yang tidak relevan dalam analisis. Data yang sudah dibersihkan akan lebih mudah dianalisis dan diproses.

3. **Ekstraksi Fitur:** Tahap selanjutnya adalah ekstraksi fitur, di mana informasi penting dari teks diambil untuk digunakan dalam model pembelajaran mesin. Fitur ini bisa berupa kata-kata kunci, frekuensi kata, atau representasi semantik dari teks yang diambil dari model NLP seperti BERT.
4. **Analisis Data:** Setelah data diproses dan fitur diekstraksi, langkah selanjutnya adalah menganalisis data untuk menemukan pola atau hubungan yang ada. Misalnya, dalam konteks penelitian ini, analisis akan fokus pada tema-tema yang muncul dalam diskusi kesehatan mental, seperti depresi atau skizofrenia.
5. **Visualisasi Hasil:** Untuk memahami hasil analisis, hasil akhir dari data mining biasanya divisualisasikan dalam bentuk grafik atau diagram yang menunjukkan pola atau temuan-temuan penting dalam data. Ini membantu peneliti dan pemangku kepentingan lainnya untuk mengambil keputusan berdasarkan informasi yang teridentifikasi.

2.2 BERT (Bidirectional Encoder Representations from Transformers)

BERT adalah model NLP yang dirancang untuk memahami konteks dua arah dari sebuah kata dalam kalimat. Model ini menggunakan arsitektur transformer untuk menangkap hubungan semantik antar kata. BERT dilatih menggunakan dua tugas utama, yaitu Masked Language Model (MLM) dan Next Sentence Prediction (NSP), yang memungkinkan model ini memahami konteks secara lebih mendalam. Dalam penelitian ini, BERT digunakan untuk menghasilkan embeddings teks yang merepresentasikan informasi semantik dari setiap diskusi kesehatan mental.

BERT menggunakan arsitektur transformer yang terdiri dari lapisan encoder dan decoder. Dalam model ini, encoder berfungsi untuk memproses input teks dan menghasilkan representasi vektor dari setiap kata dalam kalimat, sementara decoder berfungsi untuk menghasilkan output. Untuk memastikan BERT memahami konteks secara menyeluruh, model ini dilatih dengan dua tugas utama:

1. **Masked Language Model (MLM):** Pada tugas ini, beberapa kata dalam kalimat akan "ditutupi" (masked) dan BERT diminta untuk memprediksi kata yang hilang berdasarkan

konteks dari kata-kata lainnya. Ini memungkinkan BERT untuk belajar memahami makna kata dalam kalimat secara lebih mendalam.

2. **Next Sentence Prediction (NSP):** Dalam tugas ini, model diminta untuk memprediksi apakah dua kalimat berturut-turut dalam teks berhubungan satu sama lain atau tidak. Tugas ini memungkinkan BERT untuk memahami hubungan antar kalimat dan membantu dalam tugas-tugas seperti pemahaman teks dan klasifikasi.

BERT telah terbukti sangat efektif dalam berbagai tugas NLP, termasuk pengenalan entitas bernama (NER), analisis sentimen, dan klasifikasi teks. Dalam konteks penelitian ini, BERT digunakan untuk menghasilkan representasi fitur teks yang akan digunakan dalam model klasifikasi untuk memahami dan mengidentifikasi tema kesehatan mental dalam diskusi di media sosial.

2.3 Logistic Regression

Logistic Regression adalah algoritma pembelajaran mesin yang digunakan untuk klasifikasi biner. Model ini menggunakan fungsi sigmoid untuk memprediksi probabilitas suatu data termasuk ke dalam kelas tertentu. Logistic Regression dipilih karena sifatnya yang sederhana namun efektif, terutama ketika digunakan dengan fitur berkualitas tinggi seperti embeddings dari BERT.

Logistic Regression bekerja dengan memodelkan hubungan antara variabel independen (fitur) dengan probabilitas kelas menggunakan fungsi logistik. Fungsi logistik atau sigmoid menghasilkan output yang berada dalam rentang 0 hingga 1, yang bisa diinterpretasikan sebagai probabilitas kelas positif. Jika probabilitas lebih besar dari 0.5, data diklasifikasikan ke dalam kelas positif; jika kurang dari 0.5, data diklasifikasikan ke dalam kelas negatif.

Pada penelitian ini, Logistic Regression diterapkan untuk mengklasifikasikan tema diskusi kesehatan mental berdasarkan representasi teks yang dihasilkan oleh BERT. Keuntungan utama dari menggunakan Logistic Regression adalah kesederhanaan dan kecepatan pelatihan yang lebih tinggi dibandingkan dengan model-model yang lebih kompleks, seperti Neural Networks, meskipun dengan fitur berkualitas tinggi dari BERT, Logistic Regression tetap mampu memberikan hasil yang memadai.

2.4 Support Vector Machine (SVM)

SVM adalah algoritma yang mencari hyperplane optimal untuk memisahkan kelas-kelas dalam data. SVM sering digunakan untuk tugas klasifikasi karena kemampuannya menangani data berdimensi tinggi. Dalam penelitian ini, SVM digunakan sebagai pembandingan performa terhadap Logistic Regression.

SVM menggunakan prinsip kernel trick, di mana data yang tidak dapat dipisahkan secara linier dapat dipetakan ke ruang dimensi yang lebih tinggi menggunakan fungsi kernel. Fungsi kernel ini memungkinkan SVM untuk menemukan hyperplane yang memisahkan data dalam ruang dimensi tinggi dengan lebih efektif. Dalam penelitian ini, SVM digunakan untuk membandingkan performanya dengan Logistic Regression dalam tugas klasifikasi tema diskusi kesehatan mental.

2.5 Neural Networks

Neural Networks adalah model pembelajaran mesin yang terdiri dari lapisan neuron yang saling terhubung. Model ini memiliki kapasitas tinggi untuk menangani data kompleks tetapi membutuhkan sumber daya komputasi yang besar. Neural Networks digunakan sebagai baseline dalam penelitian ini untuk mengevaluasi efektivitas Logistic Regression.

Dalam penelitian ini, Neural Networks digunakan sebagai baseline untuk membandingkan efektivitas Logistic Regression dalam klasifikasi diskusi kesehatan mental. Meskipun Neural Networks memiliki kemampuan yang lebih besar dalam menangani data yang sangat kompleks, model ini juga membutuhkan lebih banyak sumber daya komputasi dan waktu pelatihan dibandingkan dengan Logistic Regression.

2.6 Kesenjangan Penelitian

Penelitian ini berangkat dari kesenjangan yang ada, yaitu:

1. Kurangnya eksplorasi penggunaan BERT sebagai ekstraktor fitur dalam klasifikasi diskusi kesehatan mental di media sosial.
2. Minimnya perbandingan performa antara Logistic Regression dengan model pembelajaran mesin lainnya, khususnya dalam domain kesehatan mental.

Meskipun terdapat banyak penelitian yang menggunakan NLP dan machine learning untuk analisis teks, penelitian yang secara spesifik mengaplikasikan BERT dalam klasifikasi diskusi kesehatan mental di media sosial masih terbatas. Selain itu, banyak penelitian yang belum membandingkan secara menyeluruh efektivitas Logistic Regression dengan metode lain seperti SVM dan Neural Networks dalam konteks ini. Penelitian ini bertujuan untuk mengisi kesenjangan ini dengan mengeksplorasi penggunaan BERT sebagai ekstraktor fitur dan membandingkan berbagai model klasifikasi untuk mengidentifikasi tema kesehatan mental.

2.7 Kontribusi Penelitian

Penelitian ini diharapkan memberikan kontribusi sebagai berikut:

1. Mengintegrasikan BERT untuk menghasilkan representasi fitur teks yang lebih akurat dalam tugas klasifikasi.
2. Membuktikan bahwa Logistic Regression dapat menjadi model yang efisien untuk klasifikasi teks dengan data yang kompleks.
3. Memberikan wawasan baru terkait penggunaan NLP di bidang kesehatan mental, yang dapat diterapkan pada platform media sosial lainnya.

BAB 3

METODOLOGI

3.1 Pengumpulan Data

Proses pengumpulan data merupakan langkah pertama yang sangat penting dalam penelitian ini. Data yang digunakan berasal dari platform media sosial X (misalnya, Twitter), yang memiliki banyak diskusi seputar topik kesehatan mental. Teknik yang digunakan untuk mengumpulkan data ini adalah **crawling** data, yang memungkinkan pengambilan informasi secara otomatis dari platform X menggunakan API atau library tertentu.

Langkah-langkah pengumpulan data:

1. **Identifikasi Kata Kunci:** Proses pengumpulan data dimulai dengan pemilihan kata kunci yang relevan dengan tema kesehatan mental. Kata kunci seperti “depresi,” “bipolar,” “skizofrenia,” “kecemasan,” “gangguan mood,” dan kata-kata lain yang berhubungan dengan topik ini dipilih. Selain itu, kata kunci tambahan seperti “terapi,” “dukungan,” dan “pengalaman pribadi” juga dipertimbangkan untuk mendapatkan data yang lebih beragam.
2. **Penggunaan API:** Untuk mengakses data dari platform X, digunakan library Python seperti **Tweepy** yang memungkinkan pengguna untuk berinteraksi dengan Twitter API. API ini memberikan akses untuk mengambil tweet, komentar, serta retweet yang mengandung kata kunci yang telah ditentukan.
3. **Penentuan Periode Waktu:** Data dikumpulkan dalam rentang waktu tertentu. Misalnya, periode 6 bulan terakhir atau satu tahun terakhir. Pengaturan waktu ini bertujuan untuk mendapatkan data yang relevan dengan perkembangan terbaru terkait topik kesehatan mental.
4. **Penyimpanan Data:** Setelah crawling selesai, hasil data (tweet atau posting) disimpan dalam format **CSV** atau **JSON**. Format ini memungkinkan untuk pemrosesan lebih lanjut menggunakan tools atau libraries analisis data seperti **pandas** di Python.
5. **Seleksi Data:** Hanya data yang relevan dengan topik yang dipilih yang akan diambil. Data yang tidak sesuai dengan tema atau mengandung banyak noise akan diabaikan. Seleksi ini penting untuk memastikan kualitas data yang digunakan dalam penelitian.

3.2 Preprocessing Data

Preprocessing data adalah langkah krusial untuk memastikan data yang digunakan dalam model bersih dan siap digunakan. Proses ini melibatkan beberapa tahapan yang bertujuan untuk

menghilangkan gangguan dan mengubah data mentah menjadi bentuk yang dapat diproses oleh model.

Langkah-langkah preprocessing:

1. **Cleaning:** Teks yang diperoleh dari media sosial biasanya mengandung elemen-elemen yang tidak relevan seperti **URL**, **mention** (@username), **hashtag** (#tag), dan simbol lainnya. Elemen-elemen ini dihapus menggunakan teknik ekspresi reguler atau fungsi bawaan di library Python seperti **re**.

Contoh:

- Teks asli: "Saya merasa #depresi setiap pagi <https://link.to/resource>"
 - Setelah cleaning: "Saya merasa depresi setiap pagi"
2. **Case Folding:** Proses ini mengubah seluruh teks menjadi huruf kecil (lowercase) untuk memastikan konsistensi. Hal ini juga berguna untuk menghindari adanya perbedaan antara kata yang memiliki kapitalisasi berbeda tetapi sebenarnya sama, seperti "Depresi" dan "depresi."

Contoh:

- Teks sebelum case folding: "Saya Merasa Depresi"
 - Setelah case folding: "saya merasa depresi"
3. **Tokenization:** Tokenization adalah proses pemecahan teks menjadi unit-unit kata yang lebih kecil (tokens). Token ini akan digunakan sebagai input ke dalam model untuk analisis lebih lanjut.

Contoh:

- Kalimat: "Saya merasa depresi."
 - Hasil tokenization: ["saya", "merasa", "depresi"]
4. **Stopword Removal:** Stopwords adalah kata-kata umum seperti "di," "ke," "untuk," yang tidak membawa informasi penting untuk analisis semantik. Proses ini menghapus kata-kata tersebut dari teks untuk memperkecil dimensi data yang akan dianalisis.

Contoh:

- Sebelum stopwords removal: ["saya", "merasa", "depresi"]
- Setelah stopwords removal: ["merasa", "depresi"]

5. **Stemming:** Stemming adalah proses mengubah kata-kata menjadi bentuk dasar (root form). Sebagai contoh, kata "memakan" akan diproses menjadi "makan." Tujuannya adalah untuk menyatukan variasi kata menjadi satu bentuk yang konsisten.

Contoh:

- Sebelum stemming: ["merasa", "depresi"]
- Setelah stemming: ["rasa", "depresi"]

3.3 Ekstraksi Fitur

Setelah data diproses, langkah berikutnya adalah mengubah teks yang telah diproses menjadi bentuk yang dapat dipahami oleh model pembelajaran mesin, yang dikenal dengan istilah **fitur**. Fitur ini akan menjadi input untuk algoritma klasifikasi.

Langkah-langkah ekstraksi fitur:

1. **Tokenization dengan BERT:** Untuk menghasilkan representasi numerik dari teks, digunakan model BERT. BERT memiliki tokenizer khusus yang mengonversi teks menjadi ID token yang sesuai dengan vocabularies yang ada dalam model. Setiap kata atau token yang ditemukan dalam teks akan dipetakan ke ID token yang ada.

Contoh:

- Teks: "saya merasa depresi"
 - Token: [101, 2009, 2036, 102] (ID token sesuai dengan vocab BERT)
2. **Pengolahan dengan BERT:** Token yang dihasilkan dari proses tokenization dimasukkan ke dalam model BERT untuk mendapatkan **embeddings**—representasi numerik dari teks. Embeddings ini mengandung informasi semantik yang dapat menangkap hubungan antar kata dalam konteks kalimat.
 - Hasil embeddings: Vektor numerik yang merepresentasikan kalimat atau dokumen. Sebagai contoh, kalimat "saya merasa depresi" mungkin diubah menjadi vektor seperti: [0.234, 0.678, 0.199, ...].
 3. **Penyimpanan Embeddings:** Embeddings yang dihasilkan digunakan sebagai input untuk model klasifikasi seperti Logistic Regression, SVM, dan Neural Networks. Fitur ini menggambarkan konteks semantik teks, memungkinkan model untuk melakukan klasifikasi berdasarkan pola yang terdeteksi dalam data.

3.4 Klasifikasi

Setelah fitur diekstraksi, model pembelajaran mesin diterapkan untuk mengklasifikasikan teks ke dalam kategori yang sesuai (misalnya, "depresi", "bipolar", atau "skizofrenia"). Model yang digunakan dalam penelitian ini adalah **Logistic Regression**, **Support Vector Machine (SVM)**, dan **Neural Networks**.

Langkah-langkah klasifikasi:

1. **Logistic Regression:** Algoritma ini digunakan untuk memetakan embeddings ke dalam kelas-kelas yang relevan. Logistic Regression sangat cocok untuk tugas klasifikasi biner, seperti memprediksi apakah sebuah diskusi berkaitan dengan "depresi" atau "bipolar."
 - Proses: Model ini menghitung probabilitas setiap kelas dan memilih kelas dengan probabilitas tertinggi sebagai prediksi.
2. **Support Vector Machine (SVM):** SVM membangun sebuah hyperplane yang memisahkan dua kelas dengan margin terbesar. SVM digunakan untuk membandingkan kinerja Logistic Regression dalam tugas klasifikasi ini, terutama karena kemampuannya untuk menangani data berdimensi tinggi.
 - Proses: SVM akan mencari hyperplane yang memisahkan kelas positif (misalnya, "depresi") dengan kelas negatif (misalnya, "bipolar") berdasarkan embeddings yang dihasilkan oleh BERT.
3. **Neural Networks:** Sebagai baseline, Neural Networks digunakan untuk mengevaluasi kemampuan model dalam menangani data yang lebih kompleks dan mengenali pola-pola yang lebih dalam. Neural Networks memiliki keunggulan dalam belajar dari data yang memiliki struktur yang lebih kompleks.
 - Proses: Neural Networks akan memanfaatkan beberapa lapisan tersembunyi untuk mempelajari representasi dari embeddings dan melakukan klasifikasi berdasarkan pola yang terdeteksi.

Pembagian Data:

- **Training Set:** Data dibagi menjadi dua set, dengan 80% data digunakan untuk melatih model (training set).

- **Testing Set:** 20% sisanya digunakan untuk menguji dan mengevaluasi model setelah pelatihan.

3.5 Evaluasi Model

Setelah model dilatih dan diuji, evaluasi dilakukan menggunakan beberapa metrik untuk menilai kinerja model.

Metrik yang digunakan:

1. **Akurasi:** Persentase prediksi yang benar dibandingkan dengan jumlah total data. Metrik ini memberikan gambaran umum tentang seberapa baik model bekerja.
2. **Precision:** Mengukur kemampuan model dalam memprediksi kelas positif dengan benar. Precision penting untuk aplikasi yang mengutamakan ketepatan, misalnya, dalam mendeteksi depresi.
3. **Recall:** Mengukur kemampuan model untuk mendeteksi semua contoh dalam kelas positif. Recall sangat penting ketika kita ingin memastikan bahwa semua kasus kesehatan mental terdeteksi.
4. **F1-Score:** Merupakan rata-rata harmonis antara precision dan recall. F1-Score memberikan gambaran yang lebih seimbang tentang kinerja model, terutama ketika data kelas tidak seimbang.
5. **AUC-ROC:** Mengukur kemampuan model dalam membedakan antara kelas positif dan negatif pada berbagai threshold. Ini memberikan gambaran tentang seberapa baik model dalam mengenali perbedaan antara kelas-kelas yang ada.

3.6 Validasi Hasil

Untuk memastikan bahwa model yang dibangun dapat menggeneralisasi dengan baik terhadap data yang tidak terlihat, dilakukan **cross-validation**. Salah satu metode yang digunakan adalah **5-fold cross-validation**, di mana data dibagi menjadi lima bagian, dan model diuji pada masing-masing bagian secara bergantian.

